



**Universidade de Brasília**

Instituto de Ciências Exatas  
Departamento de Ciência da Computação

## **Raciocínio Bayesiano e o UnBBayes**

Pedro da C. Abreu

Monografia apresentada como requisito parcial  
para conclusão do Bacharelado em Ciência da Computação

Orientador

Prof. Dr. Marcelo Ladeira

Coorientador

Prof. Dr. Shou Matsumoto

Brasília  
2015



**Universidade de Brasília**

Instituto de Ciências Exatas  
Departamento de Ciência da Computação

## **Raciocínio Bayesiano e o UnBBayes**

Pedro da C. Abreu

Monografia apresentada como requisito parcial  
para conclusão do Bacharelado em Ciência da Computação

Prof. Dr. Marcelo Ladeira (Orientador)  
CIC/UnB

Prof. Dr. Shou Matsumoto    Prof. Dr. Laecio Lima  
CIC/GMU                              CIC/UnB

Prof. Dr. Homero Luiz Piccolo  
Coordenador do Bacharelado em Ciência da Computação

Brasília, 11 de dezembro de 2015

# Resumo

Com o crescente interesse em aprendizado de máquina, frameworks robustos e implementações do estado da arte são uma necessidade do mundo moderno. Para isto é importante lidar com probabilidade bayesiana, a qual é capaz de lidar com o grau de crença de uma pessoa, diferentemente da probabilidade como estamos acostumados. Pensando nisso levantamos um estudo sobre aprendizado no contexto de Rede Bayesiana (BN), já que BNs provêm um excelente modelo para lidar com relações causais e probabilidade bayesiana. Para tal utilizaremos o framework UnBBayes e desenvolveremos plugins para este.

**Palavras-chave:** Aprendizado de Máquina, Rede Bayesiana, Design Pattern, UnBBayes

# Abstract

With the growing interest in machine learning, good frameworks and state of the art implementation are a need in modern world. For such we need to deal with Bayesian probability, which is able to deal with our belief of the world, something that the usual probability (i.e. physical probability) is not able of doing. With this in mind we provide a study in the of BN, since BNs provide a great model to deal with causal relations and bayesian probability. For such we shall use UnBBayes framework and implement plugins for it.

**Keywords:** Machine Learning, Bayesian Network, Design Pattern, UnBBayes

# Sumário

<b>1</b>	<b>Introdução</b>	<b>1</b>
1.1	Objetivos . . . . .	1
1.2	Estrutura da Monografia . . . . .	1
<b>2</b>	<b>Probabilidade</b>	<b>3</b>
2.1	Probabilidade física versus probabilidade Bayesiana . . . . .	3
2.2	Axiomas da Probabilidade . . . . .	4
2.3	Teorema de Bayes . . . . .	5
<b>3</b>	<b>Redes Bayesianas</b>	<b>6</b>
3.1	Definição Formal . . . . .	8
3.2	D-separation . . . . .	8
3.3	M-separation . . . . .	10
<b>4</b>	<b>Aprendizado de Redes Bayesianas</b>	<b>11</b>
4.1	Aprendizado de Parâmetros . . . . .	12
4.2	Aprendizado de Estrutura . . . . .	14
4.2.1	Busca e Pontuação . . . . .	15
4.2.2	Análise de Dependência . . . . .	18
<b>5</b>	<b>UnBBayes</b>	<b>19</b>
5.1	Design Geral . . . . .	20
5.1.1	Classes da View e Controller . . . . .	22
5.1.2	Classes da Model . . . . .	24
5.2	Plugins . . . . .	25
<b>6</b>	<b>Qualidade de Código e Design Patterns</b>	<b>27</b>
6.1	Conceitos Preliminares . . . . .	28
6.2	Padrões de Construção . . . . .	29
6.3	Padrões de Estrutura . . . . .	29

6.4	Padrões de Comportamento . . . . .	30
<b>7</b>	<b>Conclusão</b>	<b>32</b>
7.1	Atividades Realizadas . . . . .	32
7.2	Atividades que serão realizadas . . . . .	33
	<b>Referências</b>	<b>34</b>
	<b>Anexo</b>	<b>36</b>
<b>I</b>	<b>Figuras dos Design Patterns Mencionados</b>	<b>37</b>

# Lista de Figuras

3.1	Exemplo family-out . . . . .	6
3.2	Exemplo D-separation . . . . .	9
4.1	Rede Ásia . . . . .	13
4.2	Dados para Treinamento para a rede Ásia . . . . .	14
4.3	Pseudocódigo do algoritmo K2 (retirado de [10]) . . . . .	16
4.4	Pseudocódigo do algoritmo B (retirado de [4]) . . . . .	17
5.1	Diagrama de uso do UnBBayes . . . . .	20
5.2	UnBBayes UML MVC . . . . .	21
5.3	UnBBayes View e Controller . . . . .	23
5.4	UnBBayes UML MVC . . . . .	24
I.1	Diagrama UML do Design Pattern Singleton . . . . .	37
I.2	Diagrama UML do Design Pattern Factory . . . . .	38
I.3	Diagrama UML do Design Pattern Builder . . . . .	38
I.4	Diagrama UML do Design Pattern Prototype . . . . .	39
I.5	Diagrama UML do Design Pattern Adapter . . . . .	39
I.6	Diagrama UML do Design Pattern Bridge . . . . .	40
I.7	Diagrama UML do Design Pattern Composite . . . . .	40
I.8	Diagrama UML do Design Pattern Decorator . . . . .	41
I.9	Diagrama UML do Design Pattern Facade . . . . .	41
I.10	Diagrama UML do Design Pattern Proxy . . . . .	42
I.11	Diagrama UML do Design Pattern Responsibility . . . . .	42
I.12	Diagrama UML do Design Pattern Command . . . . .	43
I.13	Diagrama UML do Design Pattern Interpreter . . . . .	43
I.14	Diagrama UML do Design Pattern Iterator . . . . .	44
I.15	Diagrama UML do Design Pattern Mediator . . . . .	44
I.16	Diagrama UML do Design Pattern Null Object . . . . .	44
I.17	Diagrama UML do Design Pattern Observer . . . . .	45

I.18	Diagrama UML do Design Pattern State . . . . .	45
I.19	Diagrama UML do Design Pattern Template . . . . .	46
I.20	Diagrama UML do Design Pattern Visitor . . . . .	46



# Lista de Tabelas

4.1	Matriz $N_{ijk}$ Para Dispneia com Pais T ou C e Bronquite. . . . .	15
4.2	CPT calculada para Dispneia. . . . .	15

# Lista de Abreviaturas e Siglas

**API** Application Program Interface.

**BN** Bayesian Network.

**CPT** Conditional Probability Tables.

**DAG** Directed Acyclic Graph.

**GIA** Grupo de Inteligencia Artificial.

**GMU** George Mason University.

**GOF** Gang of Four.

**GUI** Graphical User Interface.

**ID** Influence Diagram.

**MDI** Multiple Document Interface.

**MDL** Minimum Description Length.

**MEBN** Multi Entity Bayesian Network.

**MML** Minimum Message Length.

**MSBN** Multiple-Sectioned Bayesian Network.

**MVC** Model View Controller.

**OO** Orientado a Objetos.

**PR-OWL** Probabilistic Web Ontology Language.

**UnB** Universidade de Brasília.

# Capítulo 1

## Introdução

No cotidiano do ser humano é muito comum raciocinar e tomar decisões sob condições de incerteza. Isto é tão visível e profundo para algumas pessoas que no século XVIII Bishop Butler declarou "probabilidade é o guia da vida".

Como um exemplo do quanto probabilidade é importante tome a medicina. Para um especialista médico determinar a doença de uma pessoa com base nos sintomas observados (evidências) é preciso que ele leve em conta a probabilidade daquele sintoma refletir esta ou aquela doença, pois a doença ocasiona determinado sintoma apenas com alguma probabilidade, mas não com certeza.

Podemos ainda citar vários outros exemplos, como na economia, teoria dos jogos, genética, previsão do tempo.

Pensando nisso é necessário um modelo robusto para lidar com tantas incertezas, para tanto escolhemos as BNs.

### 1.1 Objetivos

O objetivo deste trabalho é apresentar os conhecimentos adquiridos durante este semestre na disciplina de Estudos Em Inteligência Artificial com o professor Ladeira da Universidade de Brasília (UnB), com a colaboração do Doutorando Shou Matsumoto da George Mason University (GMU), através de aulas pelo skype. E também firmar bases sólidas sobre os conhecimentos que serão necessários na concepção da verdadeira monografia, isto é, o trabalho de conclusão de curso.

### 1.2 Estrutura da Monografia

Este documento é organizado da seguinte maneira: no capítulo 2 explicamos a visão probabilística necessária, isto é, firmamos a base do trabalho que se segue, como todos

axiomas e definições da probabilidade necessários. No capítulo 3 formalizamos o conceito de BNs e algumas de suas propriedades. No capítulo 4 discutimos como construí-las a partir de um conjunto de dados. No capítulo 5 explicamos o framework do UnBBayes, como ele funciona e como extendê-lo. O capítulo 6 discutimos alguns dos Design Patterns mais importantes. No capítulo 7 resumimos o trabalho do semestre e oferecemos uma prévia dos trabalhos a serem feitos nos próximos semestres.

# Capítulo 2

## Probabilidade

### 2.1 Probabilidade física versus probabilidade Bayesiana

Para entender BNs e as técnicas de aprendizado associadas, é importante entender a diferença entre a Probabilidade e Estatística padrão e a Bayesiana [17]

A Probabilidade física, também conhecida como probabilidade frequentista, foi advogada pelo matemático John Venn [27] no século XIX, identificando probabilidade com frequências dos eventos no longo prazo. A reclamação mais óbvia que surge neste modelo é que as frequências no curto prazo obviamente não casam com as calculadas, por exemplo, se jogarmos a moeda apenas uma vez, certamente concluiríamos que a probabilidade de cara é ou 1 ou 0.

Na probabilidade física tomamos a probabilidade sobre um espaço amostral  $S$  é obtida tomando-se  $P(A)$  como sendo o limite da frequência de  $f_A$  para todo  $A \subseteq S$ , isto é,

$$P(A) = \lim_{n \rightarrow \infty} f_A = \lim_{n \rightarrow \infty} \frac{n_A}{n} \quad (2.1)$$

Uma alternativa ao conceito de probabilidade física é pensar nas probabilidades como nosso grau de crença subjetivo. Esta visão foi expressa por Thomas Bayes [3] e Pierre Simon de Laplace [19] a duzentos anos atrás. Esta é uma visão mais geral da probabilidade pois leva em conta que temos crenças subjetivas em um grande variedade de proposições, muitas das quais não estão claramente ligadas a um processo físico. Por exemplo, a maioria de nós acreditamos na Hipótese de Copérnico de que a terra orbita em torno do sol, mas isto é baseado em evidencia não obviamente da mesma forma que um processo de amostragem. Isto é, ninguém é capaz de gerar sistemas solares repetidamente e observar a frequência com a qual os planetas giram em torno do sol. Seja como for Bayesianistas

estão preparados para conversar sobre a probabilidade da tese de Copérnico ser verdadeira e ainda relacionar as relações de evidências a favor e contra ela.

Bayesianismo pode ser visto como uma generalização da probabilidade física. Para isto adotamos o que David Lewis apelidou de Principal Principle [22]: sempre que se aprender uma probabilidade física de uma amostragem  $r$ , atualize sua probabilidade subjetiva para aquela amostragem  $r$ . Basicamente isto é senso comum: pense que para você a probabilidade de um colega raspar a cabeça como 0.01, mas se você aprende que ele faz isso se e somente se um dado justo for lançado e der 2, você certamente revisará sua opinião de acordo.

Daqui em diante sempre sempre que falarmos em probabilidade estaremos nos referindo a à probabilidade Bayesiana.

Tendo explicado como as probabilidades Físicas e Bayesianas são compatíveis podemos seguir para a definição dos axiomas da probabilidade.

## 2.2 Axiomas da Probabilidade

Seja  $U$  o universo de possíveis evento. Os três Axiomas de Kolmogorov [16] afirmam que:

**Axioma 2.1** *A probabilidade do acontecimento certo  $U$ , é 1:*

$$P(U) = 1$$

**Axioma 2.2** *A probabilidade de qualquer acontecimento é maior ou igual a zero*

$$\text{Para todo } X \subseteq U, P(X) \geq 0$$

**Axioma 2.3** *Dados dois acontecimentos disjuntos, a probabilidade da sua união é igual à soma das probabilidades de cada um*

$$\text{Para todo } X, Y \subseteq U, \text{ se } X \cap Y = \emptyset, \text{ então } P(X \cup Y) = P(X) + P(Y)$$

**Definição 2.1** *Probabilidade Condicional*

$$P(X|Y) = \frac{P(X \cap Y)}{P(Y)}$$

A probabilidade condicional exprime a seguinte ideia: dado que o evento  $Y$  já ocorreu, ou vai ocorrer, a probabilidade de  $X$  também ocorrer é  $P(X|Y)$

**Definição 2.2** *Independência*

$$X \perp Y \equiv P(X|Y) = P(X)$$

Dois eventos  $X$  e  $Y$  são probabilisticamente independentes se, ao condicionar sobre um, o outro permanece igual.

## 2.3 Teorema de Bayes

### Teorema 2.1 *Teorema de Bayes*

$$P(h|e) = \frac{P(e|h)P(h)}{P(e)}$$

Este teorema diz que a probabilidade de uma hipótese  $h$  condicionada sobre alguma evidência  $e$  é igual à multiplicação da crença a priori  $P(h)$  pela verossimilhança  $P(e|h)$ . Desta forma  $P(e|h)$  é chamada de probabilidade a posteriori.

É importante observar que  $P(h|e) + P(\neg h|e) = 1$  e isto implica que  $P(e|h)P(h) + P(e|\neg h)P(\neg h) = P(e)$

## Capítulo 3

# Redes Bayesianas

Uma BN provê uma representação compacta de distribuições de probabilidades grandes demais para lidar usando especificações tradicionais e provê um método sistemático e localizado para incorporar informação probabilística sobre uma dada situação.

Uma BN é um Directed Acyclic Graph (DAG) que representa uma função de distribuição de probabilidades conjunta de variáveis que modelam certo domínio de conhecimento. Ela é constituída de uma DAG, de variáveis aleatórias (também chamadas de nós da rede), arcos direcionados da variável pai para a variável filha e uma Conditional Probability Tables (CPT) associada a cada variável.




Figura 3.1: Exemplo family-out

Nesse exemplo, suponhamos que se queira determinar se a família está em casa ou se



ela saiu. Pelo grafo, podemos perceber que o fato de a luz da varanda estar acesa e de o cachorro estar fora de casa são indícios de que a família tenha saído.

Nas últimas décadas, redes Bayesianas se tornaram representações populares para codificar conhecimento incerto para sistemas especialistas [14]. Mais recentemente, pesquisadores desenvolveram métodos de aprendizagem de redes Bayesianas a partir de dados. As técnicas desenvolvidas são relativamente novas e ainda em evolução, mas eles têm se mostrado muito eficientes para alguns problemas de análise de dados.

Existem diversas representações possíveis para análise de dados, entre elas, decision trees, e redes neurais artificiais; e outras tantas como estimação de densidade, classificação, regressão e clusterings. Portanto o que métodos de BNs têm a oferecer? Segundo Heckerman [14] podemos oferecer pelo menos quatro respostas, sendo elas:

1. BNs lidam com um conjunto incompleto de dados de maneira natural.
2. BNs permitem aprender sobre as relações causais. Aprender sobre tais relações são importantes por pelo menos duas razões: O processo é útil quando se está tentando entender sobre um dado problema de domínio, como por exemplo, durante uma análise de dados exploratória. E mais, conhecimento de relações causais nos permitem fazer predições na presença de intervenções. Por exemplo, um analista de mercado pode querer saber se é lucrativo aumentar o investimento em determinada propaganda para aumentar as vendas de seu produto. Para responder esta pergunta o analista pode determinar se esta propaganda é a causa para o aumento de suas vendas, e em caso afirmativo, quanto. O uso de BNs nos ajuda a responder tal pergunta até mesmo quando não há experimentos nos efeitos de tal propaganda.
3. BNs em conjunto com técnicas estatísticas bayesianas facilitam a combinação de conhecimento de domínio e dados. Qualquer um que tenha feito uma análise do mundo real sabe a importância de conhecimento prévio ou de domínio, em especial quando os dados são poucos ou caros. Pelo fato de alguns sistemas comerciais (i.e., sistemas especialistas) podem ser construídos a partir de conhecimentos prévios. BNs possuem uma semântica causal que permitem conhecimentos prévios serem representados de uma forma muito simples e natural. Além disto, BNs encapsulam tais relações causais com suas probabilidades. Consequentemente, conhecimento prévio e dados podem ser combinados com técnicas bem estudadas da estatística Bayesiana.
4. Métodos Bayesianos em conjunto com BNs e outros tipos de modelos oferecem uma forma eficiente para evitar over fitting dos dados. Não há necessidade de excluir parte dos dados do treinamento do aprendizado da rede. Usando técnicas

Bayesianas, modelos podem ser "suavizados" de tal forma que todo dado disponível pode ser usado para o treinamento.

Neste capítulo oferecemos a definição formal de BN e introduzimos a propriedade de d-separation. Segundo J. Pearl [2], é esta propriedade que permite BNs serem um formalismo tão robusto para lidar com incerteza, pois é o que nos permite ignorar informação que não é importante. "Permissão para ignorar é o que dá combustível para sistemas semânticos" completa ele.

### 3.1 Definição Formal

Formalmente, portanto, uma Rede Bayesiana é uma 3-upla  $B := (N, E, P)$  onde  $G := (N, E)$  forma um DAG, isto é um grafo acíclico e direcionado.  $P$  é a probabilidade disjunta das variáveis. Considere a BN contendo  $n$  nós,  $X_1$  até  $X_n$ , tomados nesta ordem. Uma instanciação da distribuição disjunta de probabilidade é representada por  $P(X_1 = x_1, X_2 = x_2, \dots, X_n = x_n)$ , ou de forma compacta  $P(x_1, x_2, \dots, x_n)$ . A **regra da cadeia** nos permite fatorar probabilidades disjuntas como:

$$P(x_1, x_2, \dots, x_n) = P(x_1)P(x_2|x_1) \dots P(x_n|x_1, \dots, x_{n-1}) = \prod_i P(x_i|x_1, \dots, x_{i-1}) \quad (3.1)$$

No entanto, a estrutura de uma BN implica que o valor de um nó em particular é condicionado apenas aos valores dos nós pais, o que reduz a equação acima à:

$$P(x_1, x_2, \dots, x_n) = \prod_i P(x_i|pa_i) \quad (3.2)$$

Onde  $pa_i$  são os nós pais de  $x_i$

### 3.2 D-separation

Segundo Cheng[6] Uma rede bayesiana pode ser vista como um sistema de rede de canais de informação, onde cada nó é uma válvula que está aberta ou fechada e as válvulas são conectadas por canais de informação ruidosos (arestas). O fluxo de informação pode passar por uma válvula aberta, mas não por uma válvula fechada. Quando todas as válvulas sobre um caminho entre dois nós não estão abertas, diz-se que este caminho é aberto. Se qualquer válvula no caminho está fechada, diz-se que o caminho é fechado.

Formalmente um caminho  $c$  é dito ser d-separado (ou bloqueado) por um conjunto de nós  $Z$  se e somente se:

- $c$  contém uma cadeia  $i \rightarrow m \rightarrow j$  ou uma divergência  $i \leftarrow m \rightarrow j$  tal que o nó do meio  $m$  está em  $\mathbf{Z}$ ;
- $c$  contém uma convergência (ou colisor)  $i \rightarrow m \leftarrow j$  tal que o nó do meio não está em  $\mathbf{Z}$  e nenhum descendente de  $m$  está em  $\mathbf{Z}$

O conjunto  $\mathbf{Z}$  d-separa  $\mathbf{X}$  de  $\mathbf{Y}$  se e somente se,  $\mathbf{Z}$  bloqueia todos os caminhos de nós em  $\mathbf{X}$  para nós em  $\mathbf{Y}$ .

Se um caminho satisfaz a condição acima, diz-se que ele é bloqueado; caso contrário ele é ativado por  $\mathbf{Z}$ . Na figura 3.2  $X = 2$  e  $Y = 3$  são d-separados por  $Z = 1$ ; o caminho  $2 \leftarrow 1 \rightarrow 3$  é bloqueado por  $1 \in \mathbf{Z}$ .




Figura 3.2: Um DAG demonstrando d-separation; o nó 1 bloqueia o caminho 2-1-3, enquanto o nó 5 ativa o caminho 2-4-3 (retirado de [2])

Em 1988 Pearl prova que os conjuntos  $\mathbf{X}$  e  $\mathbf{Y}$  são d-separados por  $\mathbf{Z}$  em DAG se e somente se  $\mathbf{X}$  é independente de  $\mathbf{Y}$  condicionado a  $\mathbf{Z}$  em toda distribuição compatível com  $G$ .

Em outras palavras  $(\mathbf{X} \perp \mathbf{Y} | \mathbf{Z})_G \Leftrightarrow (\mathbf{X} \perp \mathbf{Y} | \mathbf{Z})_P$ , onde  $(\mathbf{X} \perp \mathbf{Y} | \mathbf{Z})_G$  significa que  $\mathbf{X}$  é d-separado de  $\mathbf{Y}$  dado  $\mathbf{Z}$  em um grafo  $G$ , e  $(\mathbf{X} \perp \mathbf{Y} | \mathbf{Z})_P$  é a independência estatística como discutido na sessão anterior.

### 3.3 M-separation

Um teste alternativo para d-separação foi proposto por Lauritzen [20], baseado na noção de grafos ancestrais e foi chamada de m-separação (separação moralizada) por Silva e Ladeira [12].

- Exclua de  $G$  todos os nós exceto aquele em  $\text{anc}(\mathbf{X} \cup \mathbf{Y} \cup \mathbf{Z})$ ;
- Conecte por uma aresta todo par de nós que possuam filho em comum (moralização);
- Remova todas orientações dos arcos

Então  $(\mathbf{X} \perp \mathbf{Y} | \mathbf{Z})_G$  se e somente se,  $\mathbf{Z}$  intercepta todos os caminhos entre  $\mathbf{X}$  e  $\mathbf{Y}$  no grafo não orientado resultante. Isto é, se removendo  $\mathbf{X}$ ,  $\mathbf{Y}$  e  $\mathbf{Z}$  ficam desconectados, então  $\mathbf{X}$  e  $\mathbf{Y}$  são condicionalmente independentes dado  $\mathbf{Z}$ , caso contrário  $\mathbf{X}$  e  $\mathbf{Y}$  são dependentes dado  $\mathbf{Z}$ . Onde  $(\text{anc}(W))$  contém os nós de  $W$  e todos seus ancestrais.

O Benefício de m-separação sobre a d-separação é o fato de ser um processo algorítmico e portanto fácil de se implementar.

## Capítulo 4

# Aprendizado de Redes Bayesianas

Muitas vezes, quando queremos construir uma BN, o conhecimento do relacionamento de causa entre as variáveis do nosso domínio pode ser incerto, o custo de um especialista muito elevado, e principalmente, precisar as probabilidades dos de cada nó dados seus pode ser inviável. No entanto, se tivermos dados sobre o problema, isto pode facilitar muito esse processo de criação da BN, tudo que precisamos fazer é adaptar técnicas de aprendizado de máquina para o escopo de BNs. Pensando nisto o interesse em desenvolver e implementar estas técnicas vem aumentando nos últimos anos.

É importante observar que as probabilidades representadas por BN pode ser Bayesiana ou Física. Quando construímos uma BN a partir de conhecimento prévio tão somente, as probabilidades serão Bayesianas. No entanto se aprendermos estas estruturas a partir de dados, estas probabilidades serão físicas [14].

O aprendizado de uma BN é dividido em duas etapas distintas e independentes

- O Aprendizado da Estrutura da rede. Isto é, quais as relações de causas entre as variáveis do nosso domínio.
- O Aprendizado dos Parâmetros da rede. Isto é, dada a estrutura da rede, quais as probabilidades de cada um dos nós.

Obviamente para se aprender os parâmetros de uma rede é necessário que já se tenha a estrutura da pronta. Esta estrutura pode ter sido construída por um especialista, ou aprendida pelos dados. Entretanto o aprendizado de parâmetro é trivial de ser feito e por este motivo já se tornou uma tradição entre as publicações sobre de Aprendizado de Redes Bayesianas apresentar a aprendizagem de parâmetros antes da aprendizagem de estrutura. Nós também seguiremos esta tradição.

## 4.1 Aprendizado de Parâmetros

O aprendizado de parâmetros nada mais que encontrar a distribuição de probabilidade conjunta de cada variável aleatória presente na rede, representadas por CPTs, dada a topologia da rede.

Seja  $\mathbf{X} = X_1, X_2, \dots, X_n$  para o conjunto de variáveis aleatórias do model,  $B(S)$  para a estrutura da BN e  $\theta_s$  para os parâmetros da BN. Pearl [2] provou que a função de distribuição conjunta de  $\mathbf{X}$  pode ser obtida como o produto das distribuições de probabilidades condicionais da variável da BN, dado os seus pais. A partir da Equação 3.2 temos que:

$$P(\mathbf{X}|\theta_s, B(S)) = \prod_{i=1}^n p(x_i|pa_i, \theta_i, B(S)) \quad (4.1)$$

Onde  $\theta_i$  é o vetor de parâmetros para  $P(x_i|pa_i, \theta_i, B(S))$ ,  $\theta_s$  é o vetor de parâmetros de  $(\theta_1, \dots, \theta_n)$ . O que desejamos é encontrar os parâmetros  $\theta_s$  dado um conjunto de treinamento  $D$  e a estrutura  $B(S)$ . Para isto avaliamos a expressão  $P(\theta_s|D, B(S))$ . É importante notar que  $D$  deve ser um conjunto de treinamento completo e é representado por  $x_1, x_2, \dots, x_n$ , onde cada  $x_i$  representa um caso do conjunto de dados observados. As incertezas são codificadas sobre os parâmetros  $\theta_s$  por uma variável aleatória  $\Theta_s$  e a função a priori  $P(\theta_s|B(S))$ . A função  $P(x_i|pa_i, \theta_i, B(S))$  é vista como a função de distribuição local.

A partir de manipulações aritméticas que fogem do escopo deste trabalho chegamos na seguinte equação:

$$P(X_i = x_i^k | Pais = pa_i^j) = \frac{\alpha_{ijk} + N_{ijk}}{\sum_i^{r_i} \alpha_{ijk} + N_{ij}} \quad (4.2)$$

Seja o domínio de  $X_i$  denotado por  $D_{x_i}$

- $X_i$  é a  $i$ -ésima variável da rede bayesiana;
- $x_i^k \in D_{x_i}$  é a  $k$ -ésima instância da variável  $X_i$ ;
- $pa_i^j$  é a  $j$ -ésima instância da variável  $X_i$ ;
- $\alpha_{ijk}$  é o parâmetro da distribuição de Dirichlet;
- $r_i$  é a cardinalidade dos estados da variável  $X_i$ , de  $D_{x_i}$ ;
- $N_{ij}$  é o número total de ocorrências de  $X_i$  dados os seus pais;  $pa_i^j$ , isto é,  $N_{ij} = \sum_{k=1}^n N_{ijk}$

Os parâmetros  $\alpha_{ijk}$  podem ser substituídos por 1, pois corresponde ao valor esperado da frequência de cada estado, admitindo-se uma distribuição uniforme para os estados de

$X_i$ , visto que, a princípio, não se tem nenhuma informação que permita estimação melhor para essa distribuição de probabilidades.

A seguir daremos um exemplo da aplicação dessa fórmula para o aprendizado da rede Ásia 4.1 proposto por Lauritzen e Spiegelhalter [21]. A tabela com os dados foi retirada de [11]




Figura 4.1: Rede Ásia

**Exemplo 4.1** Neste exemplo desejamos aprender os parâmetros para a variável dispnéia da rede Ásia, a partir do conjunto de treinamento apresentado na Tabela 4.2

Os pais da variável da variável Dispneia são TouC (coluna 4) e Bronquite (coluna 6), portanto  $pa_7 = [4, 6]$ . Os estados de TouC e Bronquite são, respectivamente representados por:

- $D_x[4] = [0, 1]$ , onde 0 representa 'Não' e 1 'Sim';
- $D_x[6] = [0, 1]$ , onde 0 representa 'Ausente' e 1 representa 'Presente'.

As possíveis instâncias para Dispneia são:  $pa_7 = [[0, 0]^0, [0, 1]^1, [1, 0]^2, [1, 1]^3]$  onde por exemplo a instância 2:  $[1, 0]^2$  representa TouC assumindo o valor 'Sim' e Bronquite assumindo o valor 'Ausente'.

A matriz  $N_{ijk}$  para dispnéia, obtida através da contagem na matriz D das ocorrências de Dispneia, condicionadas as instâncias possíveis para os pais TouC e Bronquite, está apresentada na Tabela 4.1

A partir dessa tabela é possível calcular a probabilidade associada a cada parâmetro da distribuição de probabilidade da variável aleatória Dispneia. A tabela de probabilidades condicionais de Dispneia, calculada com a 4.2, está representada na Tabela 4.2

	Ásia	Tuberculose	Fumante	Câncer	TouC	RaioX	Bronquite	Dispneia
01	Não	Ausente	Sim	Ausente	Não	Normal	Presente	Presente
02	Não	Ausente	Sim	Ausente	Não	Normal	Ausente	Ausente
03	Não	Presente	Sim	Ausente	Não	Normal	Ausente	Ausente
04	Não	Ausente	Não	Ausente	Não	Normal	Ausente	Presente
05	Não	Ausente	Sim	Ausente	Não	Normal	Ausente	Ausente
06	Não	Ausente	Sim	Ausente	Não	Normal	Ausente	Ausente
07	Não	Ausente	Não	Ausente	Não	Normal	Presente	Presente
08	Sim	Ausente	Sim	Presente	Sim	Anormal	Presente	Presente
09	Não	Ausente	Não	Ausente	Não	Normal	Ausente	Ausente
10	Não	Ausente	Não	Ausente	Não	Normal	Ausente	Ausente
11	Não	Ausente	Sim	Ausente	Não	Normal	Ausente	Presente
12	Sim	Ausente	Sim	Ausente	Não	Normal	Presente	Presente
13	Não	Presente	Não	Ausente	Não	Normal	Presente	Presente
14	Não	Ausente	Sim	Ausente	Não	Normal	Presente	Ausente

Figura 4.2: Exemplo de conjunto de treinamento para a Rede Ásia

## 4.2 Aprendizado de Estrutura

O Objetivo da aprendizagem da Estrutura é encontrar a topologia da BN que mais se adéqua aos nossos dados. Para isto podemos atacar o problema de duas formas distintas:

- Busca e pontuação: fazemos uma busca no conjunto de todos DAG existentes entre nossas variáveis usando heurísticas robustas o suficiente.
- Análise de dependência: utilizamos técnicas estatísticas bem desenvolvidas para analisar a dependência entre nossos dados e a partir deles inferir a estrutura da rede.

Vamos começar discutindo sobre algoritmos de busca e pontuação, apresentamos as heurísticas mais famosas e descrevemos o algoritmo K2 e o B. Em seguida apresentaremos os algoritmos baseados em dependencia condicional, os quais dependem fortemente do



Tabela 4.1: Matriz  $N_{ijk}$  Para Dispnea com Pais T ou C e Bronquite.

	Instancia dos Pais			
Dispnea	0	1	2	3
0	3	2	1	0
1	1	7	0	0

Tabela 4.2: CPT calculada para Dispnea.

	TouC	0	0	0	1
	Bronquite	0	1	0	1
Dispnea	Sim	$\frac{1+3}{2+4} = 0.67$	$\frac{1+2}{2+9} = 0.27$	$\frac{1+1}{2+1} = 0.67$	$\frac{1+0}{2+0} = 0.5$
	Não	$\frac{1+1}{2+4} = 0.33$	$\frac{1+7}{2+9} = 0.73$	$\frac{1+0}{2+1} = 0.33$	$\frac{1+0}{2+0} = 0.5$

conceito de d-separação, uma vez que é a d-separação que nos permite fazer asserções acerca da dependência das variáveis na rede.

### 4.2.1 Busca e Pontuação

A ideia dos algoritmos de Busca e Pontuação consiste em procurar pela rede que melhor se adere aos nossos dados dentro do universo de todas redes possíveis, isto é, que maximize a probabilidade posterior de acordo com os dados. No entanto este problema foi demonstrado ser NP-Completo [7], podendo se tornar NP-Hard caso o tamanho do banco de dados seja grande o suficiente [8]. Seja como for, boas técnicas heurísticas são necessárias para maximizar esta busca.

As funções de pontuação mais famosas são:

- Cooper & Herkovits [10] derivaram a seguinte função a partir de algumas suposições básicas, listadas mais a seguir:

$$CH(X_i, pa_i) = \prod_{j=1}^{q_i} \frac{(r_i - 1)!}{(r_i + N_{ij} - 1)!} \cdot \prod_{k=1}^{r_i} N_{ijk} \quad (4.3)$$

- Minimum Description Length (MDL)[6] é baseado na ideia que o melhor modelo é uma coleção de dados que minimiza a soma do comprimento de dados que codifica o modelo.

$$MDL(X_i, pa_i) = \left( \prod_{j=1}^{q_i} \prod_{k=1}^{r_i} N_{ijk} \log \frac{N_{ijk}}{N_{ij}} \right) - \frac{1}{2} q_i (r_i - 1) \log N \quad (4.4)$$

- Similarmente ao MDL, a heurística Minimum Message Length (MML) busca minimizar o comprimento da mensagem codificada.

$$MML(X_i, pa_i) = \log_2 n + \frac{n(n-1)}{2} - \log_2 Bits \quad (4.5)$$

onde BITS é a quantidade de bits necessária para codificar a ordenação total das variáveis.

## O Algoritmo K2

```

1. procedure K2;
2. {Input: A set of  $n$  nodes, an ordering on the nodes, an upper bound  $u$  on the
3.   number of parents a node may have, and a database  $D$  containing  $m$  cases.}
4. {Output: For each node, a printout of the parents of the node.}
5. for  $i := 1$  to  $n$  do
6.    $\pi_i := \emptyset$ ;
7.    $P_{old} := g(i, \pi_i)$ ; {This function is computed using equation (12).}
8.   OKToProceed := true
9.   while OKToProceed and  $|\pi_i| < u$  do
10.    let  $z$  be the node in  $Pred(x_i) - \pi_i$  that maximizes  $g(i, \pi_i \cup \{z\})$ ;
11.     $P_{new} := g(i, \pi_i \cup \{z\})$ ;
12.    if  $P_{new} > P_{old}$  then
13.       $P_{old} := P_{new}$ ;
14.       $\pi_i := \pi_i \cup \{z\}$ 
15.    else OKToProceed := false;
16.  end {while};
17.  write('Node:',  $x_i$ , 'Parents of this node:',  $\pi_i$ )
18. end {for};
19. end {K2};

```

Figura 4.3: Pseudocódigo do algoritmo K2 (retirado de [10])

Juntamente da métrica CH Cooper & Herkovits [10] definiram um algoritmo muito simples de aprendizado que denominaram K2, pois era visto como uma melhoria de um algoritmo já existente, o Katató.

A ideia principal do algoritmo K2 é inserir nós de forma gulosa<sup>1</sup> entre as variáveis até que nenhum nó seja capaz de aumentar a probabilidade da rede. Para isto é necessário informar uma ordem total entre os nós.

Primeiramente assume-se quatro fatores para se aplicar o algoritmo:

1. As variáveis do banco de dados são discretos. Caso os dados hajam valores contínuos é necessário discretizá-los.

---

<sup>1</sup>Busca gulosa: do inglês greedy search

2. Os casos ocorrem de forma independente. Por exemplo, se uma moeda é justa (50% de chance de cair cara), então o fato do primeiro lançamento dar cara não influencia nossa crença do segundo lançamento também dar cara.
3. Não há casos com valores faltantes.
4. As estruturas são igualmente prováveis.

Na Figura 4.3 apresentamos o pseudocódigo do algoritmo K2, onde  $\pi_i \equiv pa_i$ , isto é, os pais de  $x_i$  e  $g(i, \pi_i)$  é alguma métrica de pontuação.

## O Algoritmo B

**Input:** A variable  $\mathbf{x}$  and a prior on its parent sets  $Pr(\Pi_{\mathbf{x}})$ , and a training sample.

**Output:** The parent lattice for  $\mathbf{x}$  corresponding to this sample.

**Algorithm:** Set *Best-posterior* to the posterior for  $\Pi_{\mathbf{x}} = \emptyset$ . Set *Open-list* to  $\{\emptyset\}$ . This maintains a list of parent sets within a factor  $C$  of *Best-posterior*, those to be further expanded during search. Set *Alive-list* to  $\{\emptyset\}$ . This maintains a list of parent sets within a factor  $D$  of *Best-posterior*, that are considered alive in the parent lattice. Repeat the process below until *Open-list* becomes empty. Take the top parent set  $\Pi_{\mathbf{x}}$  from *Open-list*. If its posterior is  $< E \cdot \text{Best-Posterior}$ , mark this parent set dead. If its posterior is  $< D \cdot \text{Best-Posterior}$  ignore this parent set and proceed. Otherwise, generate all its children and calculate their posterior probabilities conditioned on the training sample. If the greatest posterior is  $> \text{Best-Posterior}$ , then update *Best-Posterior* and modify *Alive-list* to reflect the new maximum. Mark all children with posterior  $< E \cdot \text{Best-Posterior}$  such that the sample size is  $O(|\mathcal{X}| |v(\Pi_{\mathbf{x}})|)$  as dead. Add all children with posterior  $> D \cdot \text{Best-Posterior}$  to *Open-list*. Add all children with posterior  $> C \cdot \text{Best-Posterior}$  to *Alive-list* and mark them as alive. Mark all remaining unmarked children as asleep.

Figura 4.4: Pseudocódigo do algoritmo B (retirado de [4])

O algoritmo B proposto em 1991 por Buntine [4] nada mais é que uma generalização do K2 utilizando beam search. A ideia de Buntine era propor um algoritmo e extendê-lo

para ser capaz de aplicar incremental learning, isto é, poder adicionar dados e continuar o aprendizado da rede mesmo depois de ela pronta, sem necessitar fazer recomputações desnecessárias.

Beam search é uma especialização do Breadth-first search, com parâmetros de quantos sucessores devemos expadir. Portanto o algoritmo B recebe quatro parâmetros  $1 > C > D > E$ . Se a posterior da estrutura for menor que E marcamos aquela estrutura como morta, isto é, não se explora mais seus descendentes. C e D são os parâmetros do Beam Search. Quando C, D e E se aproximam de 1 o algoritmo se reduz ao K2.

Além disto também devemos informar uma ordenação total das variáveis, assim como no algoritmo K2.

A Figura 4.4 mostra um pseudocódigo do algoritmo B.

Outros algoritmos que podemos citar são as árvores de chowliu[9], kutató[15], K2, Wong-Xiang[29], Lam-Bacchus[18], Benedict[1], Suzuki[26], Friedman-Goldszmidt[?].

### 4.2.2 Análise de Dependência

Para a classe de algoritmos de Análise de Dependência é assumido que a estrutura da rede representa perfeitamente as dependências e independências do domínio. A validade de uma independência pode ser verificada realizando-se um teste estatístico usando o banco de dado sobre o domínio. A idéia geral desta classe de algoritmos é a seguinte:

1. Iniciar com um grafo não direcionado sobre  $V$ ;
2. Remover o Arco entre dois nós  $u$  e  $v$  para o qual um conjunto de variáveis  $S \subseteq V \setminus \{uv\}$  pode ser encontrado tal que  $u$  e  $v$  são condicionalmente independentes dados  $S$ ;
3. Selecionar arcos e nós e associar uma direção aos arcos para formar um  $v$ -nó na estrutura
4. Associar direções aos arcos restantes tal que um grafo direcionado acíclico seja formado.

A diferença básica entre os vários algoritmos neste enfoque está no modo como os conjuntos de variáveis  $S$  são encontrados e nas regras de associação da direcionalidade.

Podemos citar como exemplos os algoritmos CBL [5] e indução causal, proposto por Pearl [24]

# Capítulo 5

## UnBBayes

O UnBBayes é a ferramenta que expandiremos ao longo dos próximos semestres para desenvolver novos algoritmos. UnBBayes é uma aplicação open-source feita em Java<sup>TM</sup> desenvolvido pelo Grupo de Inteligencia Artificial (GIA) do Departamento de Ciência da Computação da UnB no Brasil e provê um framework para construir modelos gráficos probabilísticos e realizar raciocínios plausíveis. Ele apresenta uma Graphical User Interface (GUI), Application Program Interface (API) e ainda suporte a plug-ins para extensões não previstas.

[25, UnBBayes: a Java Framework for probabilistic models in AI] descreve os três objetivos principais das mais novas versões do UnBBayes, são eles:

- Ser uma plataforma para a disseminação dos conceitos e utilidade do raciocínio probabilístico;
- Ser uma ferramenta visual fácil de usar e configurar;
- Fornecer extensibilidade.

O Primeiro objetivo é atingido com a implementação do estado da arte de BN e um algoritmo de inferência padrão baseado no algoritmo de Junction Trees. O segundo através de uma a implementação de GUI intuitiva. E a terceira através da natureza orientada a objetos do Java<sup>TM</sup> em conjunto com um design de plug-ins.

O projeto oferece um repositório que incluem plug-ins para BN, Influence Diagram (ID), Multiple-Sectioned Bayesian Network (MSBN), Multi Entity Bayesian Network (MEBN), Probabilistic Web Ontology Language (PR-OWL), aprendizado de parametros, aprendizado de estrutura e aprendizado incremental de BNs, data mining, avaliação de classificação e performance e análise estatística de dados e finalmente diversos algoritmos para inferencia Bayesiana. A Figura 5.1 ilustra um diagrama de caso de uso do UnBBayes core<sup>1</sup>.

---

<sup>1</sup>O core é uma aplicação com um mínimo de funcionalidades.




Figura 5.1: Um exemplo de diagrama de uso do UnBBayes core (módulo de BN e da GUI (Retirado de...))

## 5.1 Design Geral

O UnBBayes é basicamente estruturado no design pattern Model View Controller (MVC) (ver capítulo 6).

A Figura 5.2 ilustra o design geral do UnBBayes.




Figura 5.2: uma classe UML ilustrando o design MVC do UnBBayes, em nível de pacotes. (Retirado de [25])

Apesar do UnBBayes ser escrito em Java<sup>TM</sup> que é uma linguagem tipicamente Orientado a Objetos (OO), o UnBBayes raramente aplica uma orientação a objetos pura em seu design. Mas ao invés, ela segue uma adaptação do paradigma orientado a componentes, o qual organiza os pedaços de código em conjuntos destacáveis e substituíveis. Componentes como num circuito eletrônico, como por exemplo circuitos integrados.

Designs baseados em componentes provêem uma alta variabilidade e reusabilidade, o que são alguns dos grandes requerimentos mencionados na seção anterior. Isto porque para fazer modificações no programa, basta substituir aquele componente por um outro. Por exemplo se precisarmos trocar o formato de um nó basta substituir o objeto que o renderiza. O que significa dizer que não há necessidade de entrar dentro de uma classe já pronta e configurar aquelas linhas de código.

O módulo core do UnBBayes provê duas funcionalidades mestras: a infraestrutura base (por exemplo, suporte às telas, acesso aos arquivos, suporte a plug-ins) e uma manipulação de BN com funcionalidades básicas (por exemplo inferência e manipulação). A seguir listamos os pacotes que compõem o core (Figura 5.2 apresentou suas dependências gerais).

- `unbbayes.controller`: Contem as classes do controller do MVC
- `unbbayes.draw`: Contem os adapters para determinar como um grafo é desenhado na tela. Permite diversas funcionalidades para desenhar, incluindo redimensionar, colorir, mover, etc.
- `unbbayes.evaluation`: Contém classes para estimar a BN

- `unbbayes.gui`: contem as Classes das GUI (por exemplo panels, windows, forms, tables).
- `unbbayes.io`: contem classes para armazenamento de BN, configurações, preferências, logs como arquivos.
- `unbbayes.prs`: contem classes representando estrutura de dados e algoritmos (classes da model do MVC.) Elementos conceituais (Node, Edge, Network, Junction-Tree, PotentialTable) e as operações entre eles . PRS vem de Probabilistic Reasoning System, isto é, o sistema de raciocínio probabilístico. Classes nesse pacote representam a BN, classes no `unbbayes.prs.id` representa uma ID, e classes no `unbbayes.prs.hubrdbn` representa uma hybrid BN, que inclui nós contínuos com valor numérico.
- `unbbayes.example`: contem classes exemplificando o uso da API do UnBBayes.
- `unbbayes.util`: este pacote unifica as classes de utilidade, os quais são classes de propósito gerais utilizados. Classes colocadas aqui provêm as seguintes funcionalidades: debugging, classes abstratas para design patterns e manipulação de coleções avançadas.
- `*.resources`: pacotes com este padrão de nome contêm classes de recursos, os quais provêm funcionalidade de localização. O class loader32 do UnBBayes pode selecionar as classes de recursos apropriados automaticamente, dependendo das configurações do computador.
- `*.extension`: pacotes com esse padrão de nome contêm classes implementando funcionalidades relacionadas à infra-estrutura de plug-in.
- `*.exception`: pacotes com esse padrão de nome contem classes representando classes de exceção.

### 5.1.1 Classes da View e Controller

A lista a seguir oferece uma breve descrição das classes ilustradas na Figura 5.3

- `NamedWindowBuilder`: este é um builder que instancia uma janela interna. Cada janela instanciada por estes builders terão um identificador (nome) e será colocado no `MDIDesktopPane`. Esta classe elimina dependencia direta do `MainController` às classes do módulo de BN (por exemplo `NetworkWindow`)
- `NetworkWindowBuilder`: a builder para `NetworkWindow`



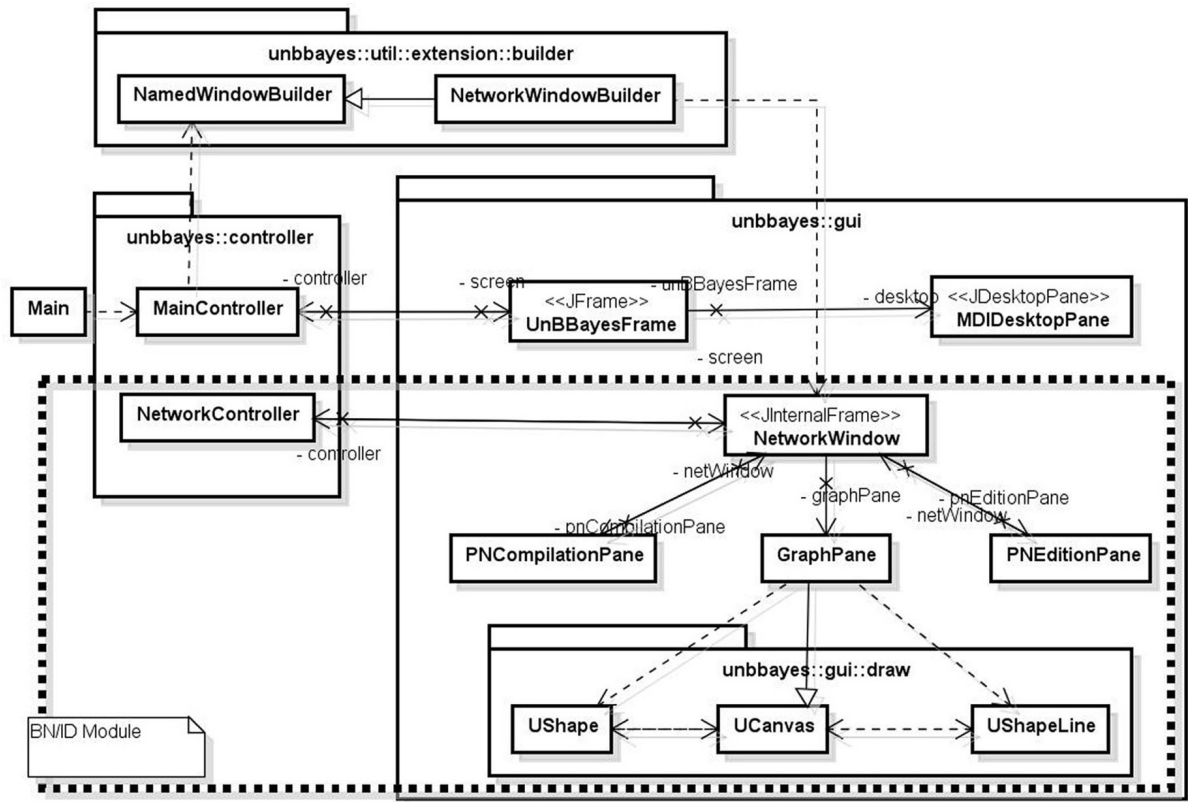


Figura 5.3: Classes do UnBBayes (core) implementando a View e o Controller do MVC (Retirado de [25])

- **MainController:** este é o controlador responsável por criar, carregar e salvar redes que o UnBBayes suporta. Também lida com as configurações de sistema.
- **UnBBayesFrame:** esta é uma extensão do swing JFrame responsável pelo painel principal do UnBBayes.
- **MDIDesktopPane:** Esta é uma extensão do swing JDesktopPane e oferece suporte à funcionalidade Multiple Document Interface (MDI) (isto é, múltiplas janelas dentro de uma janela pai). Esta classe também lida com as barras de scroll para quando a janela interna move muito para a direita ou para baixo da janela principal.
- **NetworkController:** este é o controlador responsável por engatilhar as operações do módulo de BN (tais como inserção de nós e propagação de evidências).
- **NetworkWindow:** esta é o frame interno onde a edição de BN é feita.
- **PNCompilationPane:** este é o painel da NetworkWindow responsável por mostrar a BN compilada e oferecer os meios para inserir e propagar evidências.
- **GraphPane:** este é o painel da NetworkWindow responsável por mostrar a representação gráfica da BN sendo editada.

- PNEditionPane: este é um painel na NetworkWindow responsável por prover as ferramentas para edição da BN
- UShape: esta classe é responsável por renderizar os nós em um canvas. Encapsulando a classe da model Node.
- UCanvas: esta classe representa o canvas onde o grafo é pintado.
- UShapeLine: esta classe é responsável por renderizar os arcos no canvas. Encapsulando a classe da model Edge.

### 5.1.2 Classes da Model

Classes desta categoria representam dados dentro da memória. A lista a seguir oferece uma breve descrição das classes da Figura 5.4:

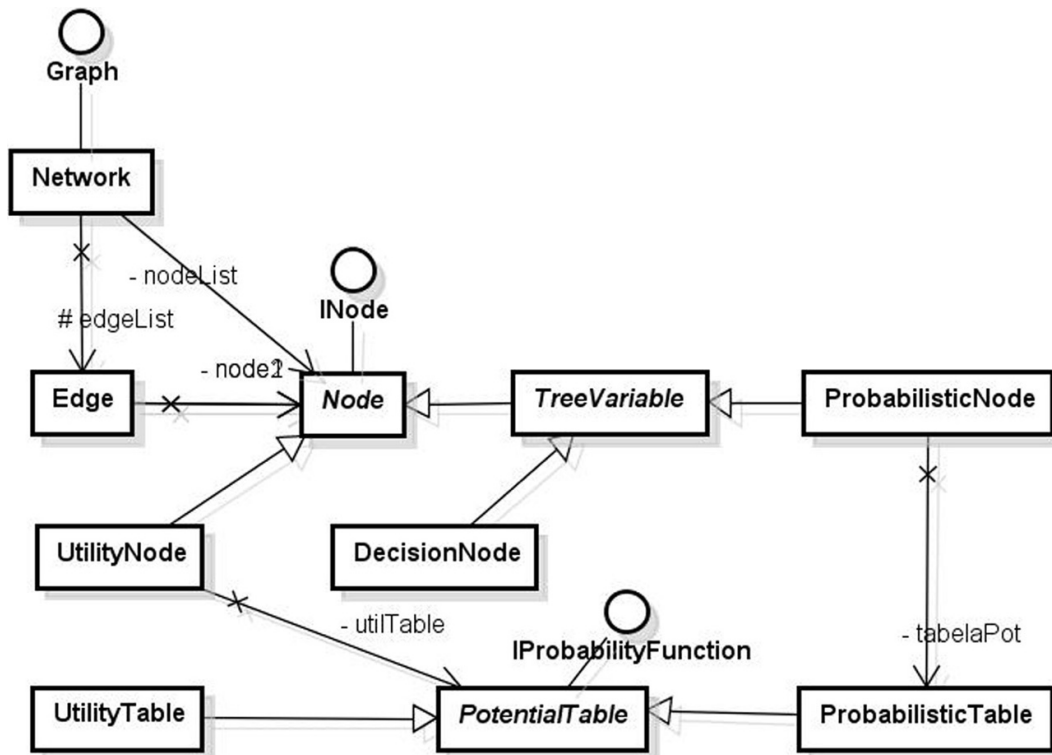


Figura 5.4: Classes do UnBBayes (core) implementando o Model (tipo de dados e operações) do MVC (Retirado de [25])

- Graph: common interface for a graph built on a set of nodes and edges
- Network: concrete implementation of a generic network. If a network is composed of probabilistic nodes, using a ProbabilisticNetwork (an extension of Network) would be useful.

- Edge: this is a class representing an edge between two nodes. By modeling relationships as a separate class, it becomes possible to use attributes, thus allowing differential treatment by other classes (e.g. how the GUI should display a relationship between two nodes depending on the edge's attributes). Technically, it is possible to create relationships (dependencies) between instances of Node without using instances of Edge, but in such case no arcs linking these two nodes will be rendered in the canvas. By doing so, it becomes possible to model "hidden" relationships.
- INode: interface representing a generic node.
- Node: abstract class representing a node. It contains additional information, such as: name, label, description, coordinates, flags<sup>36</sup>.
- TreeVariable: this is an abstract class for variables that will be displayed in the left side's swing JTree in the compilation panel. After compiling a BN, nodes that are not extending this class will be partially ignored in PNCompilationPane.
- ProbabilisticNode: it represents a probabilistic node (i.e. a node having a probabilistic assignment of values).
- UtilityNode: this is an ID's utility node.
- UtilityTable: this is a table representing an ID's utility function (which is represented as a table in UnBBayes' model).
- DecisionNode: this is an ID's decision node.
- IProbabilityFunction: this is a common interface for objects specifying a node's probabilistic distribution.
- PotentialTable: this is an abstract class representing IProbabilityFunction in a table-like format.
- ProbabilisticTable: this class represents a BN's CPT. Objects (instances) of unbayes.gui.table.GUIPotentialTable can be used to render objects of this class graphically

## 5.2 Plugins

Java<sup>TM</sup> oferece um mecanismo de fácil reuso de classes. Incorporando arquivos bytecode Java (".class" ou ".jar") no class path de outros programas, classes públicas e métodos serão disponibilizado ao programa como uma biblioteca. Como UnBBayes é disponibilizado

como um arquivo ".jar", adicioná-lo ao class path de outro programa irá garantir acesso a sua API.

Diferentemente de API's, plug-ins oferecem meios de rodar um novo código dentro do ambiente de execução do UnBBayes. Um plug-in é um programa que interage com a aplicação hospedeira (um core) e prover dada função. A ligação entre o plug-in e a aplicação core costuma acontecer em tempo de carregamento (quando a aplicação inicializa) ou em tempo de execução. Portanto, designs orientados a plugins oferecem ambientes práticos e flexíveis para prover variabilidade de software, uma vez que nenhuma modificação na aplicação hospedeira é necessária.

## Capítulo 6

# Qualidade de Código e Design Patterns

Quando falamos de projetos de grande e médio porte, a manutenibilidade e fácil adição de novas funcionalidades são preocupações essenciais. Pensando nisso, um grupo de engenheiros de software experientes (muitas vezes denominados Gang of Four (GOF)) se juntaram para compartilhar algumas das soluções dos problemas que eles encontraram ser os mais recorrentes no mundo da engenharia de software e gerencia de projetos no livro *Design Patterns: Elements of Reusable Object-oriented Software*[13]

Segundo o GOF Design Patterns são soluções de padrões de problemas que ocorrem de repetidamente nos projetos orientado a objetos. A ideia é oferecer soluções de modelagens aos projetos em nível abstrato, tirando o máximo proveito de polimorfismo, de herança e da estruturação de classes em geral.

A aplicação de design patterns é importante por diversos motivos, entre eles: Facilitam a comunicação entre desenvolvedores, aumenta a possibilidade de reuso (diminuindo, assim, o tempo de desenvolvimento e aumentando a produtividade), melhora a escalabilidade e qualidade, amplia a visão do desenvolvedor forçando-o a pensar em diversos níveis de abstração e finalmente torna o programa fácil de ser usado por terceiros.

Pelo fato de o UnBBayes ser um projeto grande o suficiente, e que tem como meta oferecer extensibilidade, é de suma importância projetar uma boa estrutura de código e manter o "código bonito", por assim dizer. Para isto, foi dado a nós, que estamos iniciando como desenvolvedores do projeto, um rápido treinamento sobre Design Patterns e Qualidade de Código.

Neste capítulo explicaremos conceitos importantes para o desenvolvimento orientado a objeto, oferecemos uma rápida explicação sobre os três tipos principais de Design Pattern, e os principais exemplos de cada um desses três tipos. No Anexo 1 oferecemos as figuras dos padrões UML de cada um dos Design Pattern mencionados

## 6.1 Conceitos Preliminares

- Acoplamento: O quanto duas (ou mais) classes dependem uma da outra para funcionar. Um alto acoplamento diminui a manutenibilidade do código pois as alterações em um código poderá ter grande impacto em todo o projeto. O ideal é que as alterações sejam atômicas, isto é, quanto menos uma alteração afetar o programa como um todo, melhor. Podemos dizer sem perda de generalidade que a essência de uma boa OO é reduzir o acoplamento.
- Coesão: Funcionalidades "bem empacotadas", isto é, cada classe, pacotes ou bibliotecas tem sua funcionalidade muito bem definida e especificada. Seus artefatos representam uma mesma categoria lógica.
- Binding: Dependências entre classes e objetos
- Open-Closed: Aberto para extensão, Fechado para alteração de fonte.
- Inversão de Controle: Separar "o que" de "quando".
- Injeção de Dependência: Especifica o objeto com o qual deve ser usado para resolver algum problema. É uma das formas de realizar inversão de Controle.
- Orientação a componentes: componentes reutilizáveis são artefatos auto-contidos, claramente identificáveis, que descrevem ou realizam uma função específica e têm interfaces em conformidade com um dado modelo de arquitetura de software, possuindo documentação apropriada e um grau de reutilização definido[28].

A ideia chave de Design Patterns é aumentar a qualidade do nosso código. Para isto, podemos seguir algumas regras básicas, tais como:

- Evitar if-else, switch-case sempre que possível utilizar polimorfismo e injeção de dependências.
- Usar interfaces em assinaturas de métodos ao invés de classes. Desta forma faremos herança única, implementação múltipla.
- Uso de protected para reforçar o conceito de open-closed.
- Métodos privados para código muito específico ou quando afeta na segurança.
- Sempre usar private em atributos.

## 6.2 Padrões de Construção

Padrões de construção abstraem o processo de instanciação. Eles podem ajudar a fazer o sistema independente de como seus objetos são criados, compostos e representados. Uma classe do padrão de construção usa herança para variar a classe que está sendo instanciada, enquanto o objeto do padrão irá delegar a instanciação para outro objeto.

Alguns dos padrões de construção mais importantes são:

- Singleton: Garante somente uma instanciação do objeto no sistema. (ver Figura I.1)
- Factory Method: Criação de objeto sem expor a lógica de criação para o cliente. (ver Figura I.2)
- Builder: Separa a classe do seu construtor. É útil quando o construtor é complexo demais. (ver Figura I.3)
- Prototype: Clona objetos (ver Figura I.4)

## 6.3 Padrões de Estrutura

Padrões de estrutura estão preocupados em como classes e objetos são compostos para formarem estruturas maiores. Elas usam herança para compor interfaces ou implementações.

Alguns dos padrões de estrutura mais importantes são:

- Adapter: Provê a ponte entre duas interfaces incompatíveis. (ver Figura I.5)
- Bridge: Provê uma interface que faz as funcionalidades de classes concretas trabalhem juntas de tal forma que alterar uma destas classes concretas não altera a outra. (ver Figura I.6)
- Composite: Cria uma classe que contém grupos de seu próprio objeto. (ver Figura I.7)
- Decorator: Cria uma classe decoradora que encapsula a classe original e provê funcionalidades adicionais, mantendo as assinaturas dos métodos originais intactas. (ver Figura I.8)
- Facade: Cria uma única classe que provê métodos simplificados requeridos pelo cliente e delega as chamadas para classes do sistema existente. (ver Figura I.9)
- Proxy: Cria um objeto proxy que possui o objeto original para fazer a interface de suas funcionalidades para o "mundo externo". (ver Figura I.10)

## 6.4 Padrões de Comportamento

Os padrões de comportamento se preocupam com os algoritmos e a distribuição de responsabilidades entre os objetos. Eles não são apenas padrões entre objetos e classes, mas também padrões de comunicação entre eles. Estes padrões caracterizam fluxo de controle difíceis de seguir em tempo de execução. Eles afastam o foco do fluxo de controle para permitir que se concentre somente na maneira como os objetos se comunicam entre si.

Alguns dos padrões de estrutura mais importantes são:

- Chain of Responsibility: Este padrão desacopla senders e receivers do pedido baseado no tipo de pedido. Normalmente cada receptor contém referência para outro receptor. Se um dos objetos não souber lidar com o pedido então ele repassa o pedido para o próximo receiver e assim por diante. (ver Figura I.11)
- Command: Um pedido é empacotado por um objeto como um comando e passado para o objeto invocador. O invocador procura o objeto apropriado para lidar com este comando.(ver Figura I.12)
- Interpreter: Provê uma forma de avaliar uma linguagem gramatical ou expressão.(ver Figura I.13)
- Iterator: Provê meios de acessar elementos de uma coleção de maneira sequencial.(ver Figura I.14)
- Mediator: Provê uma classe que lida com todas comunicações entre diferentes classes.(ver Figura I.15)
- Null Object: Provê uma classe que toma o lugar do objeto null. Muito utilizado para implementar uma "do nothing relationship".(ver Figura I.16)
- Observer: Utilizado em relações um-para-muitos entre interdependentes objetos de tal forma que se um deles mudar o outro é notificado automaticamente.(ver Figura I.17)
- State: Cria um objeto que representa vários estados e um objeto de contexto cujo comportamento varia de acordo com a mudança do objeto de estados.(ver Figura I.18)
- Template: É uma classe abstrata que define uma forma padrão de executar dado método. Isto é, as subclasses não podem fazer override desta implementação.(ver Figura I.19)



- Visitor: Provê meios de mudar o algoritmo de execução de uma dada classe. Desta forma, o algoritmo de execução pode variar de acordo com as variações do visitor.(ver Figura I.20)

# Capítulo 7

## Conclusão

Durante esse semestre de 2015/2 foram iniciados os estudos em conjunto com o Guilherme Carvalho para que desenvolvamos nosso TCC (independentemente) nos semestres que estão por vir.

Este capítulo tem por objetivo oferecer um resumo das atividades desenvolvidas no decorrer deste semestre e delinear as atividades a serem feitas nos semestres seguintes.

### 7.1 Atividades Realizadas

No decorrer deste semestre o professor Shou Matsumoto, doutorando da GMU ministrou aulas semanais às segundas via Skype sobre os conteúdos de:

1. Preparação do ambiente UnBBayes. Com o objetivo de instalar o Maven e o Subversion no eclipse e deixar o ambiente pronto para trabalhar, consertando todos possíveis problemas de dependencias;
2. Design Pattern e Anti-Patterns;
3. Arquitetura do UnBBayes;
4. Como desenvolver um Plug-in para o UnBBayes;
5. Redes Bayesianas;
6. MEBN;
7. PR-OWL;
8. Diagramas de Influência.

No decorrer do semestre também fui escalado para implementar ou consertar tarefas de usabilidade no UnBBayes. Foram elas:

1. Implementar `ctrl+c` e `ctrl+v` de nós para a extensão MEBN;
2. Implementar deleção de múltiplos findings de MEBN;
3. Refatorar a CPT para prover uma melhor visualização de tabelas muito grandes.

Para a primeira tarefa tentei refatorar o `ctrl+c` `ctrl+v` já existente no core para que cada nó saiba como se copiar, entretanto tive problemas com as chamadas de funções, pois a funcionalidade de cada nó não estava encapsulada o suficiente para fazê-lo, então por motivo de falta de tempo não pude ir adiante.

A terceira tarefa foi implementada através da não-scrollagem da primeira coluna.

## 7.2 Atividades que serão realizadas

Ficou decidido que nos semestres subsequentes será implementado um novo módulo de Incremental Learning, utilizando-se as mais novas técnicas disponíveis. E com isto analisar dados de Bactérias disponibilizados pelo professor Ladeira.

Nos primeiros meses iremos levantar um estudo do estado da arte sobre learning e incremental learning, analisar as necessidades dos dados que serão analisados, isto é, os dados tem valores faltantes? São independentes entre si? Possuem variáveis contínuas? Como visto no Capítulo 4, todas estas perguntas influenciam na escolha do algoritmo e nas técnicas que deveremos estudar nos próximos meses.

O cronograma atualizado a ser realizado nos próximos semestres pode ser encontrado em [23]. E não foi disponibilizado aqui por motivos de espaço.

Finalmente podemos concluir que este semestre foi proveitoso o suficiente para iniciar nossa compreensão em BN, learning, a ferramenta UnBBayes. E que estamos preparados para concluir uma tarefa robusta e auto-contida até o final de 2016.

# Referências

- [1] Silvia Acid e Luis M de Campos. Benedict: An algorithm for learning probabilistic belief networks. 1996. 18
- [2] Judea Pearl (Auth.). *Probabilistic Reasoning in Intelligent Systems. Networks of Plausible Inference*. Elsevier Inc, 1988. 8, 9, 12
- [3] Thomas Bayes. An essay towards solving a problem in the doctrine of chances. by the late rev. mr. bayes, f. r. s. communicated by mr. price, in a letter to john canton, m. a. and f. r. s. *Philosophical Transactions of the Royal Society*, 53:370–418, 1763. 3
- [4] Wray Buntine. Theory refinement on bayesian networks. In *Proceedings of the Seventh conference on Uncertainty in Artificial Intelligence*, pages 52–60. Morgan Kaufmann Publishers Inc., 1991. vii, 17
- [5] Jie Cheng, David Bell, e Weiru Liu. Learning bayesian networks from data: An efficient approach based on information theory. *On World Wide Web at <http://www.cs.ualberta.ca/~jcheng/bnpc.htm>*, 1998. 18
- [6] Jie Cheng, Russell Greiner, Jonathan Kelly, David Bell, e Weiru Liu. Learning bayesian networks from data: An information-theory based approach. *Artificial Intelligence*, 137(1–2):43 – 90, 2002. 8, 15
- [7] David Maxwell Chickering. Learning bayesian networks is np-complete. In *Learning from data*, pages 121–130. Springer, 1996. 15
- [8] David Maxwell Chickering, David Heckerman, e Christopher Meek. Large-sample learning of bayesian networks is np-hard. *The Journal of Machine Learning Research*, 5:1287–1330, 2004. 15
- [9] CK Chow e CN Liu. Approximating discrete probability distributions with dependence trees. *Information Theory, IEEE Transactions on*, 14(3):462–467, 1968. 18
- [10] Gregory F Cooper e Edward Herskovits. A bayesian method for the induction of probabilistic networks from data. *Machine learning*, 9(4):309–347, 1992. vii, 15, 16
- [11] Danilo Custodio da Silva. Aprendizagem estrutural de redes bayesianas com dados massivos, 2005. 13

- [12] M. Ladeira; W. da Silva. Mineração de dados em redes bayesianas. *Anais do XXII Congresso Brasileiro de computação.: Florianópolis: SBC, 2002*, pages 235–286, 2002. 10
- [13] Erich Gamma, Richard Helm, Ralph Johnson, e John Vlissides. *Design Patterns: Elements of Reusable Object-oriented Software*. Addison-Wesley Longman Publishing Co., Inc., Boston, MA, USA, 1995. 27
- [14] David Heckerman. A tutorial on learning with bayesian networks. 156:33–82, 2008. 7, 11
- [15] Edward H Herskovits e Gregory F Cooper. Kutato: An entropy-driven system for construction of probabilistic expert systems from databases. *arXiv preprint arXiv:1304.1088*, 2013. 18
- [16] A. N. Kolmogorov. *Grundbegriffe der Wahrscheinlichkeitsrechnung*. Springer, Berlin, 1933. 4
- [17] Kevin B. Korb e Ann E. Nicholson. *Bayesian artificial intelligence*. Chapman & Hall / CRC computer science and data analysis. Chapman & Hall/CRC, Boca Raton, Fla., London, 2004. 3
- [18] Wai Lam e Fahiem Bacchus. Using new data to refine a bayesian network. In *Proceedings of the Tenth international conference on Uncertainty in artificial intelligence*, pages 383–390. Morgan Kaufmann Publishers Inc., 1994. 18
- [19] P.S. Laplace e A.I. Dale. *Pierre-Simon Laplace Philosophical Essay on Probabilities: Translated from the fifth French edition of 1825 With Notes by the Translator*. Sources in the History of Mathematics and Physical Sciences. Springer New York, 2012. 3
- [20] Steffen L Lauritzen, A Philip Dawid, Birgitte N Larsen, e H-G Leimer. Independence properties of directed markov fields. *Networks*, 20(5):491–505, 1990. 10
- [21] Steffen L Lauritzen e David J Spiegelhalter. Local computations with probabilities on graphical structures and their application to expert systems. *Journal of the Royal Statistical Society. Series B (Methodological)*, pages 157–224, 1988. 13
- [22] David Lewis. A subjectivist’s guide to objective chance. In Richard C. Jeffrey, editor, *Studies in Inductive Logic and Probability*, volume 2, pages 83–132. University of California Press, 1980. 4
- [23] Abreu P. Cronograma para atividades seguintes. 33
- [24] Judea Pearl, Thomas Verma, et al. *A theory of inferred causation*. Morgan Kaufmann San Mateo, CA, 1991. 18
- [25] Matsumoto, S., Carvalho, R., Ladeira, M., Costa, P., Santos, L., Silva, D., Onishi, e M. & Machado. *UnBBayes: a Java Framework for Probabilistic Models in AI. Java in Academia and Research*, chapter UnBBayes: a Java Framework for Probabilistic Models. 2011. 19, 21, 23, 24

- [26] Joe Suzuki. Learning bayesian belief networks based on the mdl principle: an efficient algorithm using the branch and bound technique. 1996. 18
- [27] John Venn. *Logic of Chance*. 1866. 3
- [28] Cláudia Maria Lima Werner e Regina Maria Maciel Braga. Desenvolvimento baseado em componentes. *XIV Simpósio Brasileiro de Engenharia de Software. João Pessoa, Brasil*, 2000. 28
- [29] SKM Wong e Y Xiang. Construction of a markov network from data for probabilistic inference. In *Third International Workshop on Rough Sets and Soft Computing*, pages 562–569, 1994. 18

# Anexo I

## Figuras dos Design Patterns Mencionados




Figura I.1: Diagrama UML do Design Pattern Singleton

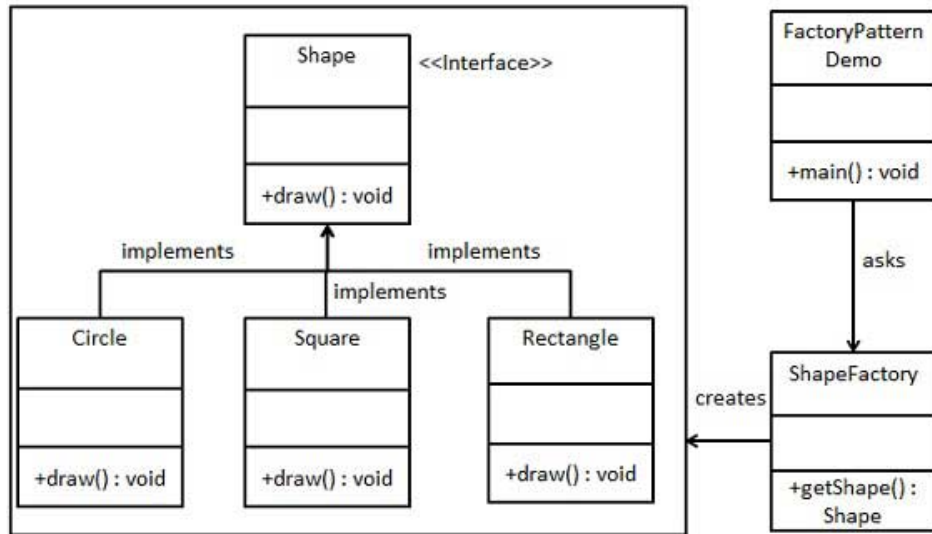


Figura I.2: Diagrama UML do Design Pattern Factory

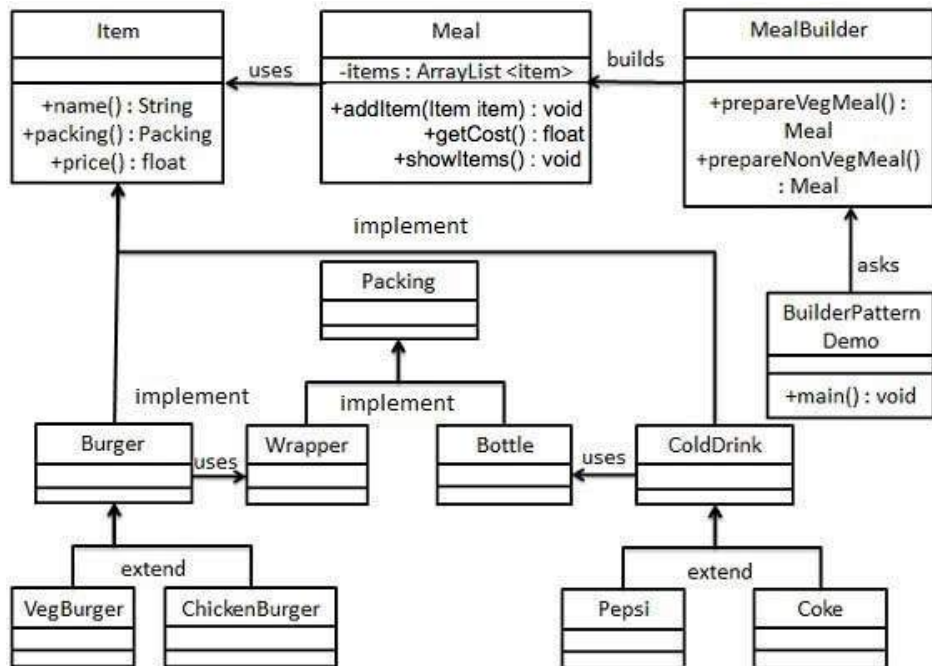


Figura I.3: Diagrama UML do Design Pattern Builder



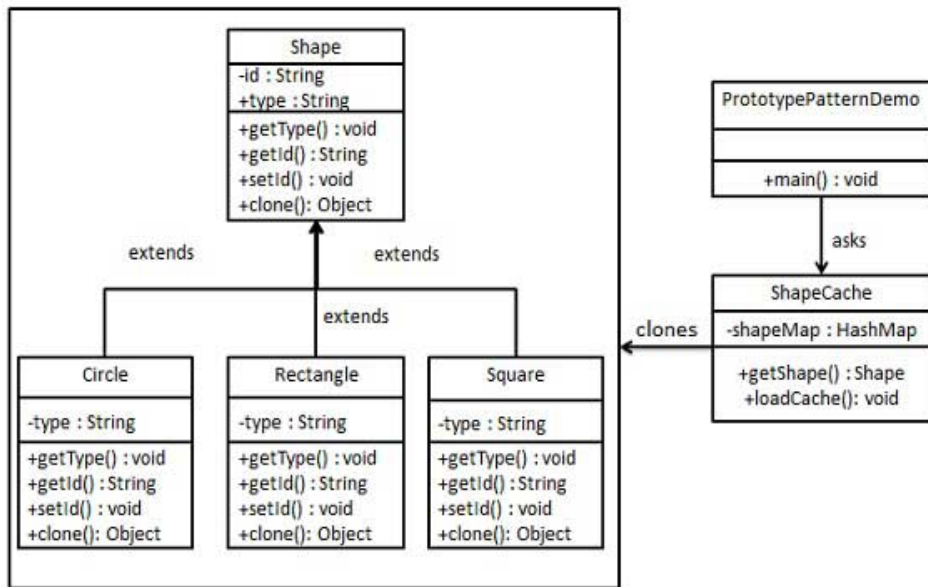


Figura I.4: Diagrama UML do Design Pattern Prototype

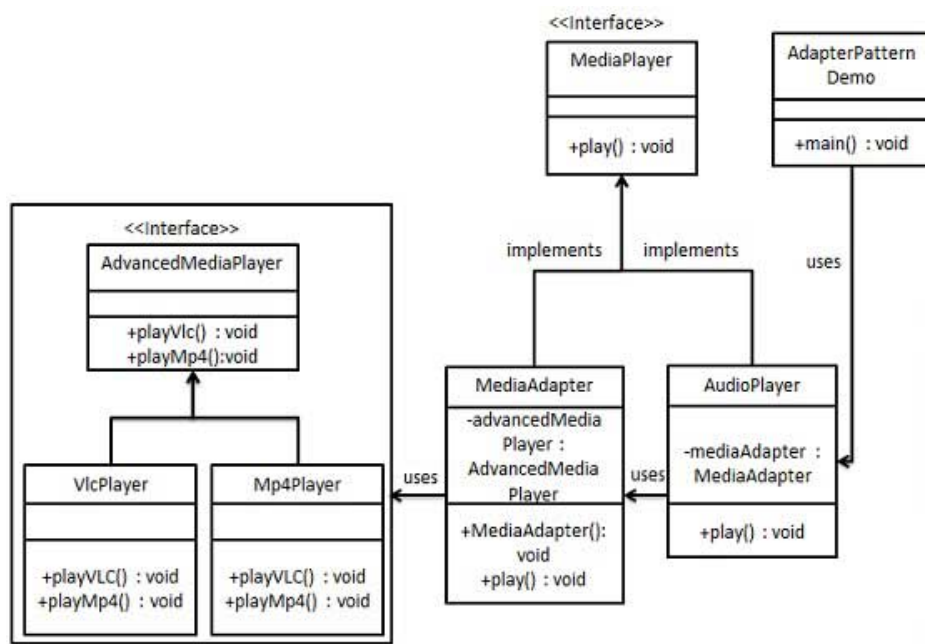


Figura I.5: Diagrama UML do Design Pattern Adapter




Figura I.6: Diagrama UML do Design Pattern Bridge

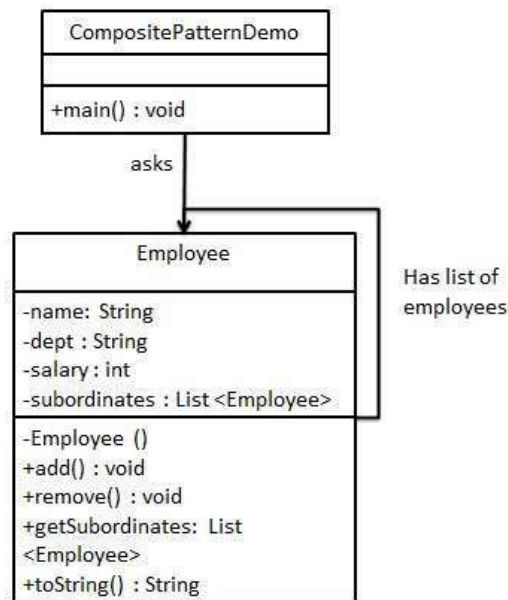


Figura I.7: Diagrama UML do Design Pattern Composite




Figura I.8: Diagrama UML do Design Pattern Decorator

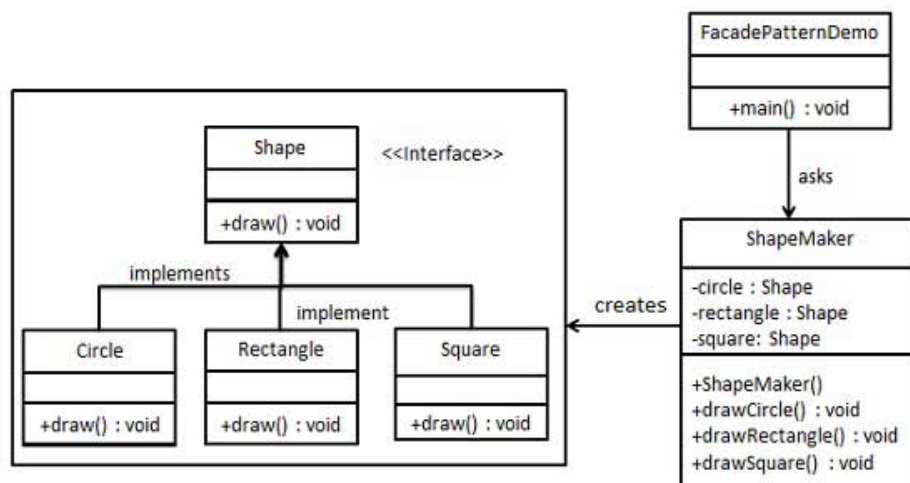


Figura I.9: Diagrama UML do Design Pattern Facade




Figura I.10: Diagrama UML do Design Pattern Proxy




Figura I.11: Diagrama UML do Design Pattern Responsibility




Figura I.12: Diagrama UML do Design Pattern Command

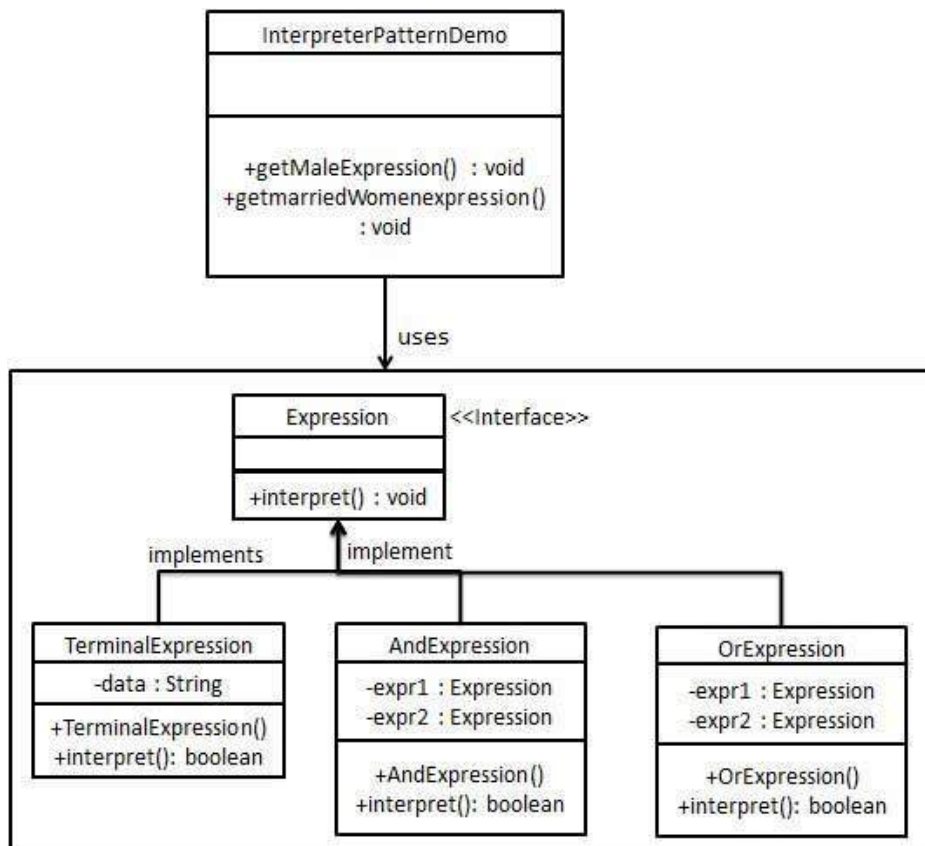


Figura I.13: Diagrama UML do Design Pattern Interpreter




Figura I.14: Diagrama UML do Design Pattern Iterator




Figura I.15: Diagrama UML do Design Pattern Mediator

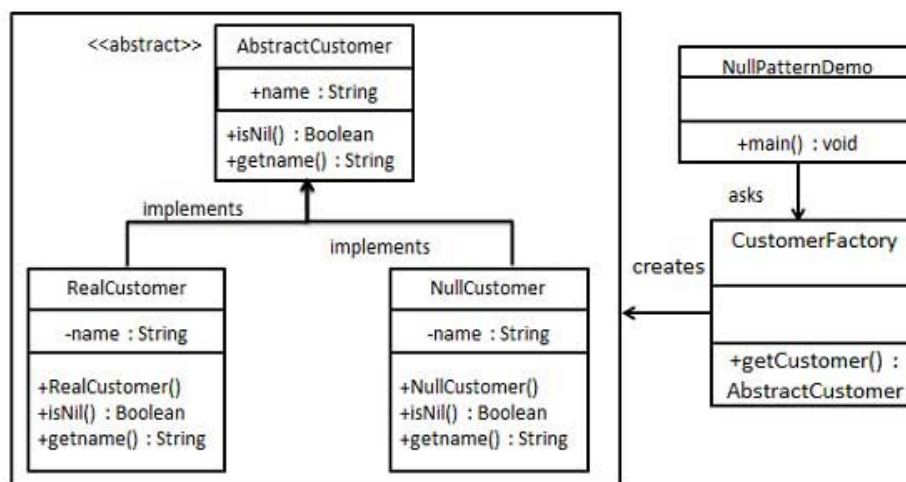


Figura I.16: Diagrama UML do Design Pattern Null Object

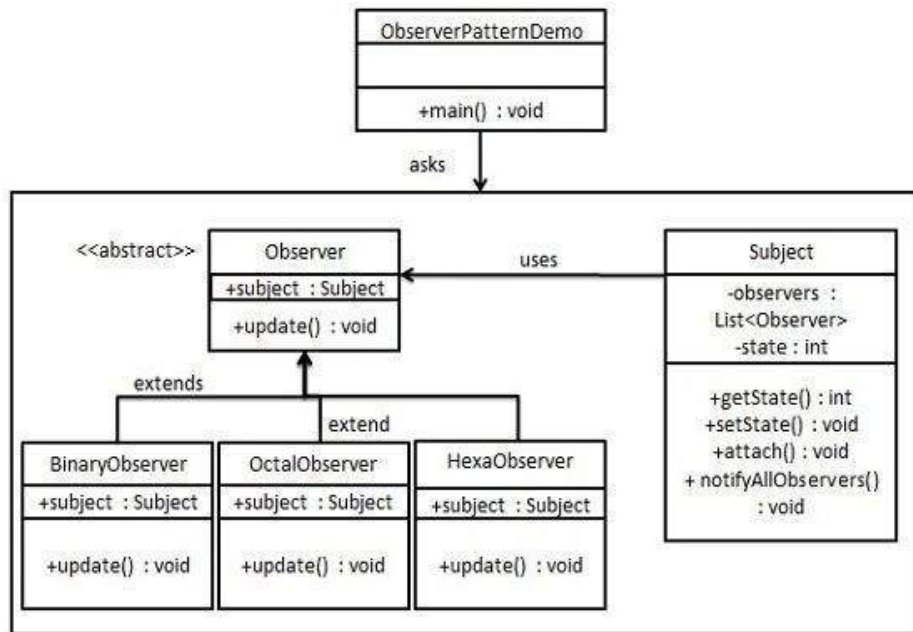


Figura I.17: Diagrama UML do Design Pattern Observer




Figura I.18: Diagrama UML do Design Pattern State




Figura I.19: Diagrama UML do Design Pattern Template




Figura I.20: Diagrama UML do Design Pattern Visitor